

ESCUELA POLITÉCNICA NACIONAL
FACULTAD DE SISTEMAS
INGENIERÍA EN CIENCIAS DE LA COMPUTACIÓN
RECUPERACIÓN DE LA INFORMACIÓN

Nombre Mark Hernández

Fecha 22/04/26

Docente Iván Carrera

Ejercicio 01: Búsqueda Básica

Objetivo: En este ejercicio vamos a implementar una búsqueda básica dentro de un corpus pequeño de textos

Pasos:

1. Leer el corpus

```
In [1]: import os

path = "C:\\Users\\mark_\\Documents\\ir26a\\data\\gutemberg\\data"
os.listdir(path)

contenidos = {}
for archivo in os.listdir(path):
    with open(os.path.join(path, archivo), "r", encoding="utf-8") as f:
        contenidos[archivo] = f.read()
    print(contenidos[archivo][:100])
```

The Project Gutenberg eBook of The Complete Works of William Shakespeare

This ebook is for the
The Project Gutenberg eBook of Pride and Prejudice

This ebook is for the use of anyone anywhere
The Project Gutenberg eBook of Middlemarch

This ebook is for the use of anyone anywhere in the
The Project Gutenberg eBook of Romeo and Juliet

This ebook is for the use of anyone anywhere i
The Project Gutenberg eBook of The Enchanted April

This ebook is for the use of anyone anywhere
The Project Gutenberg eBook of A Room with a View

This ebook is for the use of anyone anywhere
The Project Gutenberg eBook of Moby Dick; Or, The Whale

This ebook is for the use of anyone an
The Project Gutenberg eBook of Little Women; Or, Meg, Jo, Beth, and Amy

This ebook is for the
The Project Gutenberg eBook of The Round Towers of Ireland; or, The History of th
e Tuath-De-Danaans
The Project Gutenberg eBook of The Outline of History: Being a Plain History of L
ife and Mankind

The Project Gutenberg eBook of The archæology and prehistoric annals of Scotland

This ebook is
The Project Gutenberg eBook of The Blue Castle: a novel

This ebook is for the use of anyone an
The Project Gutenberg eBook of History of scientific ideas

This ebook is for the use of anyone
The Project Gutenberg eBook of Frankenstein; Or, The Modern Prometheus

This ebook is for the u

Ejemplo de lectura de contenido para 3 archivos

```
In [9]: path = "C:\\Users\\mark_\\Documents\\ir26a\\data\\gutenberg\\data"
files = [path + "\\pg84.txt", path + "\\pg100.txt", path + "\\pg145.txt"]
contenidos = {}

for file in files:
    with open(file, "r", encoding = "utf-8") as f:
        contenido = f.read()
        contenidos[file]=contenido
```

```
In [10]: for contenido in contenidos.values():
        print(contenido[:100])
```

The Project Gutenberg eBook of Frankenstein; Or, The Modern Prometheus

This ebook is for the u

The Project Gutenberg eBook of The Complete Works of William Shakespeare

This ebook is for the

The Project Gutenberg eBook of Middlemarch

This ebook is for the use of anyone anywhere in the

Lectura del número de caracteres en todo el contenido

```
In [11]: caracteres = len(contenido)
         print(caracteres)
```

1799386

Ejemplo para indicar en qué libros se encuentra la palabra "Mary" y en cuáles no

```
In [13]: buscar = "Mary"
         for file, contenido in contenidos.items():
             if buscar in contenido:
                 print(f"La palabra se encuentra en el archivo: {os.path.basename(file)}")
             else:
                 print(f"La palabra: {buscar} no se encuentra en el archivo: {os.path.bas
```

La palabra se encuentra en el archivo: pg84.txt

La palabra se encuentra en el archivo: pg100.txt

La palabra se encuentra en el archivo: pg145.txt

Ejemplo para mostrar el tiempo de ejecución de la búsqueda básica

```
In [15]: import time

         start_time = time.time()

         query = "Mary"
         encontrados = []
         for key in contenidos.keys():
             if query in contenidos[key]:
                 encontrados.append(os.path.basename(key))

         print(f"La palabra se encuentra en los siguientes archivos:\n {encontrados}")

         end_time = time.time()
         print(f"Tiempo de ejecución: {end_time - start_time} en segundos")
```

La palabra se encuentra en los siguientes archivos:

['pg84.txt', 'pg100.txt', 'pg145.txt']

Tiempo de ejecución: 0.0015614032745361328 en segundos

Definición de la función buscar_palabra

```
In [16]: def buscar_palabra(query, contenidos):
         encontrados = []
         for key in contenidos.keys():
             if query in contenidos[key]:
                 encontrados.append(key)
         return encontrados
```

Ejemplo para mostrar cuantas palabras distintas contiene el texto pg84

```
In [17]: with open(path+"\\pg84.txt", "r", encoding = "utf-8") as f:
          contenido = f.read()
          palabras = set(contenido.split())

          print(len(palabras))
```

12176

Ejemplo para verificar el tiempo de ejecución que toma buscar todas las palabras no repetidas dentro de los 14 textos

```
In [18]: start_time = time.time()
          for palabra in palabras:
              resultados = buscar_palabra(palabra, contenidos)
          end_time = time.time()
          print(f"Tiempo de ejecución: {end_time - start_time} en segundos")
```

Tiempo de ejecución: 27.323872566223145 en segundos